

Algorithms and Probability

Week 7

2025/04/03 — Georg Hasebe

Exercise Sheet 3

Exercise 1 – Probability

- (a) Consider a medical diagnostic test for a rare disease. The false negative rate is very small: if a person has a disease, with probability 0.999 the test will turn out positive. Similarly, the false-positive rate is small: if a person does not have a disease, the probability that test is positive is 0.005. Assume moreover that 1% of population has the disease in question. If a person chosen uniformly at random is tested and has positive test result, what is the probability that this person has the disease?

$A :=$ "test positive"

$B :=$ "person has disease"

$$\Pr[A|B] = 0.999$$

$$\Pr[A|\neg B] = 0.005$$

$$\Pr[B] = 0.01$$

Gesucht: $\Pr[B|A]$

Satz 2.15. (*Satz von Bayes*) Die Ereignisse A_1, \dots, A_n seien paarweise disjunkt. Ferner sei $B \subseteq A_1 \cup \dots \cup A_n$ ein Ereignis mit $\Pr[B] > 0$. Dann gilt für ein beliebiges $i = 1, \dots, n$

$$\Pr[A_i|B] = \frac{\Pr[A_i \cap B]}{\Pr[B]} = \frac{\Pr[B|A_i] \cdot \Pr[A_i]}{\sum_{j=1}^n \Pr[B|A_j] \cdot \Pr[A_j]}.$$

Theory Recap

Dichte-/Verteilungsfunktion

Sei X eine Zufallsvariable.

Dichte(funktion) von X :

$$f_X: \mathbb{R} \rightarrow [0,1], \quad x \mapsto \Pr[X = x]$$

Verteilungsfunktion von X :

$$F_X: \mathbb{R} \rightarrow [0,1], \quad x \mapsto \Pr[X \leq x]$$

Bernoulli-Verteilung

Eine Zufallsvariable X mit Wertebereich $W_X = \{0,1\}$ und der Dichtefunktion

$$f_X(x) = \begin{cases} p & x = 1, \\ 1 - p & x = 0, \\ 0 & \text{sonst} \end{cases}$$

heisst **bernoulli-verteilt**. Wir schreiben: $X \sim \text{Ber}(p)$.

Nach Definition von f_X gilt also $\Pr[X = 0] = 1 - p$ und $\Pr[X = 1] = p$.

Es gilt: $\mathbb{E}[X] = p$.

Beispiele

- Werfen einer Münze, Indikator für Kopf
- Werfen eines Würfels, Indikator für “Augenzahl gerade”
- Werfen eines Würfels, Indikator für “1”

Indikatorvariablen

Beobachtung 2.35. Für ein Ereignis $A \subseteq \Omega$ ist die zugehörige *Indikatorvariable* X_A definiert durch:

$$X_A(\omega) := \begin{cases} 1, & \text{falls } \omega \in A \\ 0, & \text{sonst.} \end{cases}$$

Für den Erwartungswert von X_A gilt: $\mathbb{E}[X_A] = \Pr[A]$.

Indikatorvariablen sind Bernoulli Variablen mit $p = \Pr[A]$.

Binomialverteilung

Bernoulli-verteilte Zufallsvariable erhalten wir zum Beispiel als Indikator für “Kopf”, wenn wir eine Münze einmal werfen.

Werfen wir die Münze n -mal und fragen wie oft wir Kopf erhalten haben, so ist die entsprechende Zufallsvariable **binomialverteilt**. Wir schreiben: $X \sim \text{Bin}(n, p)$.

Für die **Dichtefunktion** einer **binomialverteilten** Zufallsvariable X gilt:

$$f_X(x) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x} & x \in \{0, 1, \dots, n\}, \\ 0 & \text{sonst} \end{cases}$$

Es gilt: $\mathbb{E}[X] = np$

Beispiel (Blackboard)

Fünf faire Münzen werden geworfen. Sei X die Zufallsvariable, die zählt, wie oft Kopf erscheint. Bestimmen Sie den Wert $f_X(3)$ und erklären Sie, wie sie auf diesen Wert gekommen sind.

Geometrische Verteilung

Man stelle sich ein Experiment vor, bei dem eine Aktion so lange wiederholt wird, bis sie erfolgreich ist (z.B. bis das erste mal Kopf kommt).

Wenn ein einzelner Versuch mit (Erfolgs-)Wahrscheinlichkeit p gelingt, so ist die Anzahl der Versuche bis zum Erfolg **geometrisch verteilt** und man schreibt $X \sim \text{Geo}(p)$.

Für die Dichtefunktion einer **geometrisch verteilten** Zufallsvariable X gilt:

$$f_X(i) = \begin{cases} p(1-p)^{i-1} & i \in \mathbb{N}, \\ 0 & \text{sonst} \end{cases}$$

Es gilt: $\mathbb{E}[X] = 1/p$.

Beispiel (Blackboard)

Eine Urne enthält N weiße und M schwarze Bälle. Es werden zufällig Bälle aus der Urne gezogen, bis ein schwarzer Ball gezogen wird. Ein gezogener Ball wird vor dem nächsten Zug ersetzt (gleiche Farbe).

Was ist die Wahrscheinlichkeit, dass genau n Züge notwendig sind?

(*) Geometric Series

$$\bullet \sum_{k=0}^{\infty} ar^k = \frac{a}{1-r} \quad \text{for } |r| < 1.$$

$$\bullet \sum_{k=1}^n ar^{k-1} = \begin{cases} a \left(\frac{1-r^n}{1-r} \right) & r \neq 1 \\ an & \text{otherwise} \end{cases}$$

see [Wikipedia](#).



please be careful with indices!

(*) not part of the lecture; might be worth knowing.

(*) Beispiel: Geometric Series

$$X \sim \text{Geo}(p)$$

$$\begin{aligned} F_X(u) &= \Pr[X \leq n] = \sum_{k=1}^n \Pr[X = k] \\ &= \sum_{k=1}^n p(1-p)^{k-1} = p \sum_{k=1}^n (1-p)^{k-1} \\ &= p \frac{1 - (1-p)^n}{1 - (1-p)} = 1 - (1-p)^n. \end{aligned}$$

• $\sum_{k=0}^{\infty} ar^k = \frac{a}{1-r}$ for $|r| < 1$.

• $\sum_{k=1}^n ar^{k-1} = \begin{cases} a \left(\frac{1-r^n}{1-r} \right) & r \neq 1 \\ an & \text{otherwise} \end{cases}$

please be careful with indices!

see [Wikipedia](#).

(*) not part of the lecture; might be worth knowing.

Negative Binomialverteilung

Sei Z die Anzahl der Versuche bis zum n -ten Erfolg.

Für $n = 1$ haben wir $Z \sim \text{Geo}(p)$.

Für $n \geq 2$: Z ist **negativ binomialverteilt** (mit Ordnung n).

$$f_Z(z) = \binom{z-1}{n-1} \cdot p^n (1-p)^{z-n}$$

Es gilt: $\mathbb{E}[X] = n/p$.

Poisson-Verteilung

$$X \sim \text{Po}(\lambda)$$

$$f_X(i) = \begin{cases} \frac{e^{-\lambda} \lambda^i}{i!} & \text{für } i \in \mathbb{N}_0 \\ 0 & \text{sonst.} \end{cases}$$

$$\mathbb{E}[X] = \lambda$$

Bin(n, λ/n) konvergiert für $n \rightarrow \infty$ gegen Po(λ)

“Hier denke man zum Beispiel an die Möglichkeit, dass ein Bürger in der nächsten Stunde einen Herzinfarkt bekommt.
Für den Einzelnen ist dies unwahrscheinlich, schweizweit gibt es aber dennoch etwa drei bis vier pro Stunde.”
see Skript p. 127

Beispiel 3.36. Betrachten wir zum Beispiel eine einzelne Seite der “Neuen Zürcher Zeitung”. Wir nehmen an

- ▷ die Seite hätte $n = 10^4$ Zeichen,
- ▷ und die Druckmaschine setze 10^{-3} der Zeichen falsch.

Somit hat jedes Zeichen die Wahrscheinlichkeit $p = \frac{10}{n}$, falsch gesetzt zu werden.

Die Anzahl Fehler auf der Seite, M , entspricht einer binomialverteilten Zufallsvariablen mit den Parametern n und $p = \frac{10}{n}$. Durch die Poisson-Approximation ergibt sich also zum Beispiel

$$\mathbb{P}[M = 5] \approx \frac{10^5}{5!} e^{-10} = 0.0378332748020 \dots$$

$$\text{vergleich: } \mathbb{P}[X = 5] = \binom{10^4}{5} (10^{-3})^5 (1 - 10^{-3})^{10^4 - 5} = 0.037795423239 \dots$$

Coupon Collector

Szenario: es gibt n verschiedene Bilder
in jeder Runde erhalten wir (gleichw'lich) eines der Bilder

X := Anzahl Runden bis wir alle n Bilder besitzen

Frage: $E[X] = ??$

cont'd on the blackboard.

Bedingte Zufallsvariable

Sei X eine Zufallsvariable und A ein Ereignis mit $\Pr[A] > 0$.

Die **bedingte Zufallsvariable** $X|A$ ist *dieselbe Funktion* wie X , aber der Definitionsbereich ist auf die Menge A eingeschränkt.

$$X|A: A \rightarrow \mathbb{R}.$$

Bedingte Zufallsvariable

Dichtefunktion

$$f_{X|A}: \mathbb{R} \rightarrow [0,1], \quad x \mapsto \Pr[X = x | A] = \frac{\Pr[\{\omega \in A : X(\omega) = x\}]}{\Pr[A]}$$

Verteilungsfunktion

$$F_{X|A}: \mathbb{R} \rightarrow [0,1], \quad x \mapsto \Pr[X \leq x | A] = \frac{\Pr[\{\omega \in A : X(\omega) \leq x\}]}{\Pr[A]}$$

Erwartungswert

$$\mathbb{E}[X | A] := \sum_{x \in W_X} x \cdot \Pr[X = x | A] = \frac{1}{\Pr[A]} \sum_{\omega \in A} X(\omega) \cdot \Pr[\omega]$$

Bedingte Zufallsvariable

X ist unabhängig von A , falls:

$$f_{X|A} = f_X.$$

Es gilt also:

$$\Pr[X = x | A] = \frac{\Pr[\{\omega \in A : X(\omega) = x\}]}{\Pr[A]} = \Pr[X = x]$$

Beispiel

$X_1 :=$ "Augenzahl des ersten Würfels"

$X_2 :=$ "Augenzahl des zweiten Würfels"

$X := X_1 + X_2 =$ "Summe der beiden Augenzahlen"

$A :=$ " X_2 ist gerade"

Berechnen Sie $\mathbb{E}[X_1]$, $\mathbb{E}[X]$, $\mathbb{E}[X|A]$.

Zur Erinnerung:

cont'd on the blackboard.

Dichtefunktion

$$f_{X|A}: \mathbb{R} \rightarrow [0,1], \quad x \mapsto \Pr[X = x | A] = \frac{\Pr[\{\omega \in A: X(\omega) = x\}]}{\Pr[A]}$$

Verteilungsfunktion

$$F_{X|A}: \mathbb{R} \rightarrow [0,1], \quad x \mapsto \Pr[X \leq x | A] = \frac{\Pr[\{\omega \in A: X(\omega) \leq x\}]}{\Pr[A]}$$

Erwartungswert

$$\mathbb{E}[X|A] := \sum_{x \in W_X} x \cdot \Pr[X = x | A] = \frac{1}{\Pr[A]} \sum_{\omega \in A} X(\omega) \cdot \Pr[\omega]$$

Mehrere Zufallsvariablen

Mehrere Zufallsvariablen zugleich?

$$\Pr[X = x, Y = y] = \Pr[\{\omega \in \Omega \mid X(\omega) = x, Y(\omega) = y\}]$$

Weiters haben wir:

- $\Pr[X = x, Y = y]$ ist als Abkürzung von $\Pr[X = x \cap Y = y]$ zu verstehen
- gemeinsame Dichte:

$$f_{X,Y}(x, y) = \Pr[X = x, Y = y]$$

Mehrere Zufallsvariablen

Randdichte von X (= Dichte von X)

$$f_X(x) = \sum_{y \in W_Y} f_{X,Y}(x, y)$$

Good to know!



Beweis. Die Ereignisse “ $Y = y$ ” bilden eine **disjunkte Zerlegung** des Wahrscheinlichkeitsraumes.

$$\Rightarrow f_X(x) \stackrel{\text{Def.}}{=} \Pr[X = x] \stackrel{2.13}{=} \sum_{y \in W_Y} \Pr[X = x, Y = y].$$

Beispiel

$X :=$ "Augenzahl des Würfels"

$Y :=$ "Anzahl Kopf bei X -mal Münze geworfen"

Bestimmen Sie $f_{X,Y}$.

Bestimmen Sie $f_Y(6)$. Benutzen Sie $f_{X,Y}$.

Zur Erinnerung:

cont'd on the blackboard.

Mehrere Zufallsvariablen zugleich?

$$\Pr[X = x, Y = y] = \Pr[\{\omega \in \Omega \mid X(\omega) = x, Y(\omega) = y\}]$$

Weiters haben wir:

- $\Pr[X = x, Y = y]$ ist als Abkürzung von $\Pr[X = x \cap Y = y]$ zu verstehen
- gemeinsame Dichte:

$$f_{X,Y}(x, y) = \Pr[X = x, Y = y]$$

Unabhängigkeit von mehreren Zufallsvariablen

Definition 2.52. Zufallsvariablen X_1, \dots, X_n heissen unabhängig genau dann, wenn für alle $(x_1, \dots, x_n) \in W_{X_1} \times \dots \times W_{X_n}$ gilt

$$\Pr[X_1 = x_1, \dots, X_n = x_n] = \Pr[X_1 = x_1] \cdot \dots \cdot \Pr[X_n = x_n].$$

Alternativ kann man Definition 2.52 auch über die Dichten formulieren: X_1, \dots, X_n sind genau dann unabhängig, wenn für alle $(x_1, \dots, x_n) \in W_{X_1} \times \dots \times W_{X_n}$ gilt

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = f_{X_1}(x_1) \cdot \dots \cdot f_{X_n}(x_n).$$

siehe Skript S. 132.

Beispiel

Sei $\Omega = \{2,3\}$ mit $\Pr[\omega] = 1/2$ für alle $\omega \in \Omega$.

Bestimmen Sie die Indikatorvariablen X, Y wobei X bzw. Y genau dann 1 ist, wenn ω durch 2 bzw. 3 teilbar ist.

Bestimmen Sie f_X, f_Y .

Sind X und Y voneinander unabhängig?

Zur Erinnerung:

cont'd on the blackboard.

Definition 2.52. Zufallsvariablen X_1, \dots, X_n heissen unabhängig genau dann, wenn für alle $(x_1, \dots, x_n) \in W_{X_1} \times \dots \times W_{X_n}$ gilt

$$\Pr[X_1 = x_1, \dots, X_n = x_n] = \Pr[X_1 = x_1] \cdot \dots \cdot \Pr[X_n = x_n].$$

Alternativ kann man Definition 2.52 auch über die Dichten formulieren: X_1, \dots, X_n sind genau dann unabhängig, wenn für alle $(x_1, \dots, x_n) \in W_{X_1} \times \dots \times W_{X_n}$ gilt

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = f_{X_1}(x_1) \cdot \dots \cdot f_{X_n}(x_n).$$

Unabhängigkeit: Indikatorvariablen

Für zwei **Indikator**variablen X und Y gilt

$$X \text{ und } Y \text{ sind} \\ \textbf{unabhängig} \quad \Longleftrightarrow \quad f_{X,Y}(1,1) = f_X(1) \cdot f_Y(1)$$

Aufgabe 2 – *Unabhängigkeit*

Seien A und B zwei unabhängige Ereignisse. Zeigen Sie, dass dann

- (i) \bar{A} und B ,
- (ii) A und \bar{B} , sowie
- (iii) \bar{A} und \bar{B}

jeweils unabhängig sind.

Summe von Zufallsvariablen

Satz 2.58. Für zwei unabhängige Zufallsvariablen X und Y sei $Z := X + Y$. Es gilt

$$f_Z(z) = \sum_{x \in W_X} f_X(x) \cdot f_Y(z - x).$$

Beweis. Mit Hilfe des Satzes von der totalen Wahrscheinlichkeit folgt, dass

$$\begin{aligned} f_Z(z) &= \Pr[Z = z] = \sum_{x \in W_X} \Pr[X + Y = z \mid X = x] \cdot \Pr[X = x] \\ &= \sum_{x \in W_X} \Pr[Y = z - x] \cdot \Pr[X = x] = \sum_{x \in W_X} f_X(x) \cdot f_Y(z - x). \end{aligned}$$

□

Bemerkung: Die Ereignisse " $X = x$ " bilden eine **disjunkte Zerlegung** des Wahrscheinlichkeitsraumes.

Summe von Zufallsvariablen

Satz 2.58. Für zwei unabhängige Zufallsvariablen X und Y sei $Z := X + Y$. Es gilt

$$f_Z(z) = \sum_{x \in W_X} f_X(x) \cdot f_Y(z - x).$$

Folgerungen:

$$\text{Poisson}(\lambda_1) + \text{Poisson}(\lambda_2) = \text{Poisson}(\lambda_1 + \lambda_2)$$

$$\text{Bin}(n, p) + \text{Bin}(m, p) = \text{Bin}(n+m, p)$$

Waldsche Identität

Satz 2.65 (Waldsche Identität). N und X seien zwei unabhängige Zufallsvariable, wobei für den Wertebereich von N gilt: $W_N \subseteq \mathbb{N}$. Weiter sei

$$Z := \sum_{i=1}^N X_i,$$

wobei X_1, X_2, \dots unabhängige Kopien von X seien. Dann gilt:

$$\mathbb{E}[Z] = \mathbb{E}[N] \cdot \mathbb{E}[X].$$

Proof on the blackboard.

Beispiel

$X :=$ "Augenzahl des Würfels"

$Y :=$ "Anzahl Kopf bei X -mal Münze geworfen"

Was ist $\mathbb{E}[Y]$?

Zur Erinnerung:

cont'd on the blackboard.

Satz 2.65 (Waldsche Identität). N und X seien zwei unabhängige Zufallsvariable, wobei für den Wertebereich von N gilt: $W_N \subseteq \mathbb{N}$. Weiter sei

$$Z := \sum_{i=1}^N X_i,$$

wobei X_1, X_2, \dots unabhängige Kopien von X seien. Dann gilt:

$$\mathbb{E}[Z] = \mathbb{E}[N] \cdot \mathbb{E}[X].$$

Varianz

Es gibt Zufallsvariablen, die niemals Werte in der Grössenordnung des Erwartungswerts annehmen.

Beispiel: $\Pr[X = -10^6] = \Pr[X = 10^6] = 1/2$ mit $\mathbb{E}[X] = 0$.

Mass für die Abweichung vom Erwartungswert? Die **Varianz** $\text{Var}[X]$.

Varianz

Definition 2.39. Für eine Zufallsvariable X mit $\mu = \mathbb{E}[X]$ definieren wir die *Varianz* $\text{Var}[X]$ durch

$$\text{Var}[X] := \mathbb{E}[(X - \mu)^2] = \sum_{x \in W_X} (x - \mu)^2 \cdot \Pr[X = x].$$

Die Grösse $\sigma := \sqrt{\text{Var}[X]}$ heisst *Standardabweichung* von X .

Satz 2.40. Für eine beliebige Zufallsvariable X gilt

$$\text{Var}[X] = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

Satz 2.41. Für eine beliebige Zufallsvariable X und $a, b \in \mathbb{R}$ gilt

$$\text{Var}[a \cdot X + b] = a^2 \cdot \text{Var}[X].$$

both Satz 2.40 and Satz 2.41 can be proven using just Definition 2.39.

Varianz

Definition 2.39. Für eine Zufallsvariable X mit $\mu = \mathbb{E}[X]$ definieren wir die *Varianz* $\text{Var}[X]$ durch

$$\text{Var}[X] := \mathbb{E}[(X - \mu)^2] = \sum_{x \in W_X} (x - \mu)^2 \cdot \Pr[X = x].$$

Die Grösse $\sigma := \sqrt{\text{Var}[X]}$ heisst *Standardabweichung* von X .

Satz 2.40. Für eine beliebige Zufallsvariable X

$$\text{Var}[X] = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

Satz 2.41. Für eine beliebige Zufallsvariable X und $a, b \in \mathbb{R}$ gilt

$$\text{Var}[a \cdot X + b] = a^2 \cdot \text{Var}[X].$$

Keine Garantie! Selbst nachsehen!

FS 2021

ETH Zürich
Institute of Theoretical Computer Science
Dr. Johannes Lengler, Prof. Emo Welzl
Dr. Anders Martinsson, Charlotte Knierim

Algorithmen und Wahrscheinlichkeit Formelsammlung

Varianz

- **Definition:** $\text{Var}[X] := \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2$.
- **Translation:** Für $a, b \in \mathbb{R}$ gilt $\text{Var}[a \cdot X + b] = a^2 \cdot \text{Var}[X]$.
- **Standardabweichung:** $\sigma[X] := \sqrt{\text{Var}[X]}$.
- **Additivität:** Für unabhängige X_1, \dots, X_n gilt $\text{Var}[X_1 + \dots + X_n] = \text{Var}[X_1] + \dots + \text{Var}[X_n]$.

Wichtige Rechenregeln

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$$

$$\forall X, Y$$

siehe Satz 2.60 im Skript.

$$\mathbb{E}[X \cdot Y] = \mathbb{E}[X] \cdot \mathbb{E}[Y]$$

$$\forall X, Y \text{ unabhängig}$$

siehe Satz 2.61 im Skript.

$$\text{Var}[X + Y] = \text{Var}[X] + \text{Var}[Y]$$

$$\forall X, Y \text{ unabhängig}$$

siehe Satz 2.62 im Skript.

$$\text{Var}[X \cdot Y] \neq \text{Var}[X] \cdot \text{Var}[Y]$$

$$\text{i.A. (auch für unabhängige ZV)}$$

Ungleichung von Markov

Satz 2.67. (*Ungleichung von Markov*) Sei X eine Zufallsvariable, die nur nicht-negative Werte annimmt. Dann gilt für alle $t \in \mathbb{R}$ mit $t > 0$, dass

$$\Pr[X \geq t] \leq \frac{\mathbb{E}[X]}{t}.$$

Beweis. Wir rechnen direkt nach, dass

$$\begin{aligned} \mathbb{E}[X] &= \sum_{x \in W_X} x \cdot \Pr[X = x] \geq \sum_{x \in W_X, x \geq t} x \cdot \Pr[X = x] \\ &\geq t \cdot \sum_{x \in W_X, x \geq t} \Pr[X = x] = t \cdot \Pr[X \geq t]. \end{aligned}$$

Ungleichung von Chebyshev

Satz 2.68. (*Ungleichung von Chebyshev*) Sei X eine Zufallsvariable und $t \in \mathbb{R}$ mit $t > 0$. Dann gilt

$$\Pr[|X - \mathbb{E}[X]| \geq t] \leq \frac{\text{Var}[X]}{t^2}$$

Beweis. Es gilt

$$\Pr[|X - \mathbb{E}[X]| \geq t] = \Pr[(X - \mathbb{E}[X])^2 \geq t^2].$$

Die Zufallsvariable $Y := (X - \mathbb{E}[X])^2$ ist nicht-negativ und hat nach Definition der Varianz den Erwartungswert $\mathbb{E}[Y] = \text{Var}[X]$. Damit folgt die Behauptung durch Anwendung der Markov-Ungleichung:

$$\Pr[|X - \mathbb{E}[X]| \geq t] = \Pr[Y \geq t^2] \leq \frac{\mathbb{E}[Y]}{t^2} = \frac{\text{Var}[X]}{t^2}.$$

□

Aufgabe 2 – Obere Schranken

Wir werfen einen fairen 6-seitigen Würfel $n \geq 1$ mal. Sei X die Anzahl der Würfe, bei denen der Würfel ‘6’ zeigt. Berechnen Sie eine möglichst gute obere Schranken für $\Pr[X \geq 2n/9]$.

(a) Mithilfe der Ungleichung von Markov. (1 Punkte)

(b) Mithilfe der Ungleichung von Chebychev. (2 Punkte)

siehe [AlgoWahr FS21](#)

Zur Erinnerung:

Wichtige Verteilungen

Name	Bezeichnung	Wertebereich	Dichte	Erwartungswert	Varianz
Bernoulli	Bernoulli(p)	$\{0, 1\}$	$f_X(i) = \begin{cases} p & \text{für } i = 1, \\ 1 - p & \text{für } i = 0. \end{cases}$	p	$p(1 - p)$
Binomial	Bin(n, p)	$\{0, 1, \dots, n\}$	$f_X(i) = \binom{n}{i} p^i (1 - p)^{n-i}$	np	$np(1 - p)$
Geometrisch	Geo(p)	\mathbb{N}	$f_X(i) = p(1 - p)^{i-1}$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
Poisson	Po(λ)	\mathbb{N}_0	$f_X(i) = \frac{e^{-\lambda} \lambda^i}{i!}$	λ	λ

von der FS21 Formelsammlung entnommen.

- **Markov:** Ist $W_X \subseteq \mathbb{R}_{\geq 0}$ und $t \in \mathbb{R}_{\geq 0}$, so ist $\Pr[X \geq t] \leq \frac{\mathbb{E}[X]}{t}$ bzw. $\Pr[X \geq t \cdot \mathbb{E}[X]] \leq \frac{1}{t}$.
- **Chebyshev:** Für $t \in \mathbb{R}_{\geq 0}$ ist $\Pr[|X - \mathbb{E}[X]| \geq t] \leq \frac{\text{Var}[X]}{t^2}$ bzw. $\Pr[|X - \mathbb{E}[X]| \geq t \cdot \sigma[X]] \leq \frac{1}{t^2}$.

Aufgabe 2 – Obere Schranken

Wir werfen einen fairen 6-seitigen Würfel $n \geq 1$ mal. Sei X die Anzahl der Würfe, bei denen der Würfel ‘6’ zeigt. Berechnen Sie eine möglichst gute obere Schranken für $\Pr[X \geq 2n/9]$.

(a) Mithilfe der Ungleichung von Markov. (1 Punkte)

(b) Mithilfe der Ungleichung von Chebychev. (2 Punkte)

(c) Mithilfe der Chernoff-Schranken. (2 Punkte)

siehe [AlgoWahr FS21](#)

Zur Erinnerung:

- **Markov:** Ist $W_X \subseteq \mathbb{R}_{\geq 0}$ und $t \in \mathbb{R}_{\geq 0}$, so ist $\Pr[X \geq t] \leq \frac{\mathbb{E}[X]}{t}$ bzw. $\Pr[X \geq t \cdot \mathbb{E}[X]] \leq \frac{1}{t}$.
- **Chebyshev:** Für $t \in \mathbb{R}_{\geq 0}$ ist $\Pr[|X - \mathbb{E}[X]| \geq t] \leq \frac{\text{Var}[X]}{t^2}$ bzw. $\Pr[|X - \mathbb{E}[X]| \geq t \cdot \sigma[X]] \leq \frac{1}{t^2}$.
- **Chernoff:** Seien X_1, \dots, X_n unabhängig und Bernoulli-verteilt, $X := \sum_{i=1}^n X_i$ und $\delta \in [0, 1]$. Dann ist

Name	Bezeichnung	Wertebereich	Dichte	Erwartungswert	Varianz
Bernoulli	Bernoulli(p)	$\{0, 1\}$	$f_X(i) = \begin{cases} p & \text{für } i = 1, \\ 1 - p & \text{für } i = 0. \end{cases}$	p	$p(1 - p)$
Binomial	Bin(n, p)	$\{0, 1, \dots, n\}$	$f_X(i) = \binom{n}{i} p^i (1 - p)^{n-i}$	np	$np(1 - p)$
Geometrisch	Geo(p)	\mathbb{N}	$f_X(i) = p(1 - p)^{i-1}$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
Poisson	Po(λ)	\mathbb{N}_0	$f_X(i) = \frac{e^{-\lambda} \lambda^i}{i!}$	λ	λ

$$\Pr[X \geq (1 + \delta)\mathbb{E}[X]] \leq e^{-\frac{1}{3}\delta^2 \mathbb{E}[X]},$$

$$\Pr[X \leq (1 - \delta)\mathbb{E}[X]] \leq e^{-\frac{1}{2}\delta^2 \mathbb{E}[X]},$$

$$\Pr[X \geq t] \leq 2^{-t} \quad \text{für } t \geq 2e\mathbb{E}[X].$$

von der FS21 Formelsammlung entnommen.

Algorithmus

Klassischer Algorithmus:



Wir beweisen:

(1) **Korrektheit:**


für alle Eingaben I gilt: $A(I)$ ist korrekt (d.h. was es sein soll)

(2) **Laufzeit:**

für alle Eingaben I mit Länge $|I|=n$: Laufzeit = $O(f(n))$

As we have seen in AnD.


Randomisierte Algorithmen



Eigenschaften:

Ausgabe $\mathcal{A}(I, \mathcal{R})$ hängt von Eingabe I *und* Zufallszahlen \mathcal{R} ab.

Insbesondere: Ergebnis lässt sich i.A. nicht reproduzieren .. !



Randomisierte Algorithmen

Die Hinzugabe von Zufallselementen \mathcal{R} muss auch bei der Korrektheit und Laufzeit berücksichtigt werden.

(1) Korrektheit:

$$\Pr[\mathcal{A}(I, \mathcal{R}) \text{ ist korrekt}] \geq \dots$$

Wir wollen: praktisch 1...

(2) Laufzeit:

$$\mathbb{E}[\text{Laufzeit}] = O(f(n)) \quad \text{und/oder} \quad \Pr[\text{Laufzeit} \leq f(n)] \geq \dots$$

Las-Vegas/ Monte-Carlo Algorithmen

Las-Vegas Algorithmen:

- geben nie falsche Antwort
- Laufzeit ist eine Zufallsvariable

Ziel: $\mathbb{E}[\text{Laufzeit}] = \text{"polynomiell"}$

Monte-Carlo Algorithmen:

- Laufzeit immer polynomiell
- geben manchmal eine falsche Antwort

Ziel: $\Pr[\text{Antwort falsch}] = \text{"sehr klein"}$

s-brücken:

Las-Vegas = “**L**aufzeit **V**ariabel”

Monte-Carlo = “**M**anchmal **C**orrect”

Nutzung auf eigene Gefahr.

Las-Vegas Algorithmus:

- QuickSort (Laufzeit hängt von Pivotwahl ab)

Monte-Carlo Algorithmus:

- Testen einer Münze: fair (Kopf/Zahl) vs. fake (Kopf/Kopf)
- Algorithmus:** werfe Münze ~~ein~~¹⁰⁰ Mal, falls ≥ 1 mal Zahl: return „fair“
ansonsten: return „fake“
- Fehlerw'lichkeit:** 0, falls Münze fake
 $(1/2)^{100}$, falls Münze fair